

Predire il *dropout* universitario con il machine learning

RELATRICI

Youssra Zarouky · Jessica M Pucci

DATASET

UCI ML Repository · 4.424 studenti · 2008–2019

Sei capitoli per un'*indagine* sui dati.

01 Il problema

03 Cosa abbiamo scoperto

05 I risultati

02 Il dataset

04 Come funzionano i modelli

06 Riflessioni critiche

PERCHÉ QUESTO PROBLEMA CONTA

Ogni anno, migliaia di studenti abbandonano l'università.

LA DOMANDA CENTRALE


È possibile prevedere chi abbandonerà, usando le informazioni disponibili al momento dell' *iscrizione* e durante il *primo anno*?

4.424 studenti, 36 variabili, un'unica domanda.

UCI ML Repository — un'istituzione universitaria portoghese, 2008–2019.

07	Profilo demografico	Età, genere, stato civile, nazionalità, fuori sede, bisogni educativi speciali.
08	Contesto economico	Borsa di studio, situazione debitoria, rette, lavoro dei genitori, disoccupazione, inflazione, PIL.
09	Percorso scolastico	Corso scelto, frequenza diurna/serale, voto della qualifica scolastica, voto di ammissione.
12	Performance del 1° anno	Per ciascun semestre: esami accreditati, iscritti, sostenuti, superati, voto medio.

Abbiamo escluso gli *"Enrolled"* — esito non ancora definitivo.




Enrolled rimossi	794	
Dataset finale	3.630	
Graduate	2.209	60,85%
Dropout	1.421	39,15%

Zero esami al primo semestre, un segnale *inequivocabile*.


10:1

Su **dieci** studenti senza alcun esame superato al primo semestre, **uno solo** completerà il percorso.




L'ETÀ DI INGRESSO

Dopo i *22 anni* il rischio sale — e questo chiede risposte istituzionali.



Il dato mostra una **correlazione**, non una causa. Suggerisce **servizi dedicati** per chi si iscrive in fasce d'età non tradizionali.

Il supporto economico fa la *differenza*.



DAL SEGNALE PIÙ DEBOLE → AL PIÙ FORTE

Turno di frequenza

Diurna leggermente più protettiva.

Genere

Le studentesse completano più spesso.


Borsa di studio

Effetto protettivo netto.

Situazione debitoria

La separazione più netta tra tutte.


Cosa *distingue* davvero un percorso completato da uno interrotto?



Tre metodi diversi convergono sulle **stesse variabili**. Il risultato è *robusto*, non dipendente da un singolo algoritmo.

DALL'ALBERO ALLA FORESTA

Il modello impara a fare le *domande giuste*.




DECISION TREE

Un diagramma di flusso che impara **domande sì/no** dai dati. Trasparente, ma **instabile**.

RANDOM FOREST

Cento alberi votano. Gli errori si compensano, il segnale comune si rafforza.

Più *profondo* non significa più preciso.



Come uno studente che *memorizza* le soluzioni degli esami passati. Il modello deve imparare i **principi**, non i casi specifici.

LA BASELINE

Cosa riesce un modello che *non sa nulla*?

Un classificatore che predice *sempre* la classe più frequente (Graduate), senza guardare alcuna variabile.

MODELLO	F1 DROPOUT	F1 GRADUATE	F1 MACRO	ACCURACY
Baseline · predice sempre Graduate	0,00	0,71	0,36	60,85%

Non identifica **nessuno** studente in difficoltà — eppure ha il **60,85% di accuracy**. L'accuracy è fuorviante: per questo usiamo l'**F1-Score** che valuta la precisione nell'identificare le singole categorie.

IL CONFRONTO FINALE


Dal più semplice al più *complesso*.

Modello	Accuracy	F1 Graduate	F1 Dropout	F1 Macro
<i>Baseline (Dummy)</i>	0.609	0.757	0.000	0.378
Logistic Regression	0.898	0.915	0.873	0.894
Decision Tree	0.894	0.914	0.863	0.888
Random Forest	0.906	0.924	0.877	0.901
MLP (rete neurale)	0.898	0.919	0.862	0.891

Modello migliore – su 100 studenti, ne classifica correttamente ≈ 90 .

L'**F1 Macro** misura quanto bene il modello identifica *entrambe* le classi, non solo la più frequente.

Decision Tree e Random Forest *concordano.*



Il primo anno è determinante. Queste informazioni esistono già nei sistemi degli atenei — disponibili a metà del primo anno.

Cosa funziona — e cosa dobbiamo ancora *risolvere*.

LIMITE 01 · IL PIÙ RILEVANTE

Timing delle variabili più predittive

Le informazioni del 1° e 2° semestre sono disponibili **solo dopo** che lo studente le ha vissute.

LIMITE 02

Contesto unico

Una sola istituzione portoghese, 2008–2019.

LIMITE 03

Variabili escluse

Corso di laurea e nazionalità, per ragioni tecniche.

LIMITE 04

Ottimizzazione parziale

C'è ancora margine sui parametri dei modelli.

Un modello non è neutro — le domande che *non possiamo ignorare.*

01 Chi accede alle previsioni e come le usa?

Un'etichetta usata bene apre una conversazione di supporto. Usata male, diventa pregiudizio.

02 Alcune variabili introducono disparità di trattamento?

Genere e fascia d'età entrano nelle previsioni: è una scelta consapevole — da discutere, non da dare per scontata.

03 Cosa succede quando il modello si sbaglia?

Il modello è uno strumento di supporto, non un verdetto. La decisione finale spetta sempre a una persona.

Domande?

Codice, notebook e grafici sono pubblici su GitHub.



`github.com/jessica-m-pucci/
student-dropout-ml`